

СОДЕРЖАНИЕ

СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ	3
ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ.....	4
ВВЕДЕНИЕ	5
1 Теоретические основы прогнозирования временных рядов.....	8
1.1 Понятие временного ряда и особенности временных данных	8
1.2 Основные свойства и компоненты временного ряда	9
1.3 Подходы к прогнозированию временных рядов	14
1.4 Классические подходы к прогнозированию временных рядов	15
1.5 Нейросетевые подходы к прогнозированию временных рядов.....	20
1.6 Метрики оценки качества прогнозирования временных рядов.....	26
1.7 Выводы по главе	29
2 Методика и проведение вычислительного.....	32
2.1 Дизайн вычислительного эксперимента	32
2.2 Используемые данные	36
2.3 Предобработка данных	38
2.4 Реализация вычислительного эксперимента	40
3 Анализ результатов вычислительного эксперимента	44
3.1 Общие результаты эксперимента.....	44
3.2 Многокритериальное сравнение моделей	51
3.3 Итоговые выводы по результатам эксперимента	54
4 Разработка программной системы.....	56
ЗАКЛЮЧЕНИЕ	61
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	63
ПРИЛОЖЕНИЕ А	66
ПРИЛОЖЕНИЕ В	68

СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ

ARIMA — Autoregressive Integrated Moving Average, авторегрессионная интегрированная модель скользящего среднего

ETS — Error, Trend, Seasonality, семейство моделей экспоненциального сглаживания

LSTM — Long Short-Term Memory, долговременная краткосрочная память

MAE — Mean Absolute Error, средняя абсолютная ошибка

MAPE — Mean Absolute Percentage Error, средняя абсолютная процентная ошибка

MSE — Mean Squared Error, средняя квадратичная ошибка

N-BEATS — Neural Basis Expansion Analysis for Interpretable Time Series Forecasting, нейросетевая архитектура для интерпретируемого прогнозирования временных рядов

RMSE — Root Mean Squared Error, корень из средней квадратичной ошибки

RNN — Recurrent Neural Network, рекуррентная нейронная сеть

sMAPE — Symmetric Mean Absolute Percentage Error, симметричная средняя абсолютная процентная ошибка

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

Горизонт прогнозирования — будущий интервал времени, для которого строится прогноз временного ряда

Датасет — структурированная коллекция данных, подготовленная для анализа, исследования или обучения моделей

Дифференцирование временного ряда — преобразование временного ряда, основанное на вычислении разностей между соседними наблюдениями, применяемое для уменьшения тренда и достижения стационарности

Нормализация данных — преобразование значений признаков к единому масштабу

Обучающая выборка (train set) — часть данных, используемая для обучения модели

Переобучение (overfitting) — ситуация, при которой модель слишком точно запоминает обучающие данные и хуже работает на новых данных

Предиктор — параметр или признак, используемый для прогнозирования

Скользящее окно — последовательный набор соседних наблюдений временного ряда, используемый как вход модели прогнозирования

ВВЕДЕНИЕ

Во многих областях данные фиксируются последовательно во времени, поэтому их удобно рассматривать как временные ряды. В таком формате могут быть представлены экономические показатели, метеорологические наблюдения, медицинская статистика, данные о пользовательской активности и многие другие процессы. Для таких данных важно не только само значение показателя, но и то, как оно меняется во времени [1].

Актуальность темы связана с тем, что прогнозирование временных рядов помогает оценивать возможное поведение процессов в будущем. Это важно для планирования ресурсов, анализа рисков, выявления отклонений и поддержки принятия решений. Прогнозирование временных рядов используется во многих сферах: от экономики и логистики до медицины, энергетики и климатических исследований. При этом точность прогноза во многом зависит не только от самих данных, но и от того, насколько удачно выбран подход к их анализу.

Сегодня существует большое количество методов прогнозирования временных рядов. Классические статистические модели, такие как ARIMA и методы экспоненциального сглаживания, применяются уже длительное время и до сих пор широко используются на практике. Это связано с их сравнительно простой реализацией, интерпретируемостью и относительно невысокими вычислительными затратами. Одновременно с этим активно развиваются и нейросетевые подходы, способные выявлять более сложные зависимости в данных без явного задания правил анализа.

При этом нельзя утверждать, что нейросетевые модели всегда обеспечивают более высокое качество прогноза. Эффективность модели во многом определяется особенностями временного ряда: объёмом данных, наличием сезонности, уровнем шума, длиной ряда и другими характеристиками. Кроме того, более сложные модели обычно требуют значительных вычислительных ресурсов и более трудоёмкой настройки. В

связи с этим задача сравнительного анализа классических и нейросетевых моделей в одинаковых условиях остаётся актуальной.

Степень разработанности темы можно оценить как достаточно высокую. Существуют исследования, посвящённые как классическим методам прогнозирования временных рядов, так и современным нейросетевым архитектурам. Однако часто такие работы рассматривают отдельные группы моделей или используют ограниченный набор данных. Также результаты разных исследований не всегда удобно сопоставлять между собой, поскольку могут отличаться датасеты, схемы предобработки, метрики и подходы к настройке моделей. В связи с этим представляет интерес сравнительный анализ моделей на временных рядах различной природы при использовании единой методики эксперимента.

Целью выпускной квалификационной работы является проведение сравнительного анализа классических и нейросетевых моделей прогнозирования временных рядов на данных различной природы, а также разработка программной системы, реализующей данный анализ.

Для достижения поставленной цели необходимо решить следующие задачи:

- 1) Провести анализ предметной области и существующих подходов к прогнозированию временных рядов.
- 2) Рассмотреть особенности временных рядов различной природы и факторы, влияющие на качество прогнозирования.
- 3) Осуществить сбор, подготовку и предварительную обработку временных рядов.
- 4) Провести вычислительный эксперимент по сравнительному анализу моделей прогнозирования временных рядов.
- 5) Выполнить анализ и интерпретацию результатов проведённого эксперимента.
- 6) Разработать программную систему, реализующую сравнительный анализ моделей прогнозирования временных рядов.

Практическая значимость работы заключается в том, что в ней формируется воспроизводимая методика сравнения моделей прогнозирования временных рядов. Кроме того, в рамках работы разрабатывается программная система, позволяющая запускать эксперимент, получать прогнозы, рассчитывать метрики и сравнивать результаты моделей в единых условиях. Полученные результаты могут быть полезны при выборе подходящего подхода к прогнозированию для временных рядов с разными характеристиками.

1 Теоретические основы прогнозирования временных рядов

1.1 Понятие временного ряда и особенности временных данных

Во многих областях часто стоит задача прогнозирования каких-либо показателей, из-за чего данные стали собирать в формате временных рядов.

Временной ряд представляет собой набор последовательных наблюдений, упорядоченных во времени. Он включает в себя два обязательных элемента: время и конкретное значение показателя, или уровень ряда.

Именно зависимость данных от времени является ключевым отличием временных рядов от других выборок. Это обуславливает ряд особенностей, из-за которых анализ и прогнозирование временных рядов выделяют в отдельную дисциплину.

Для лучшего понимания особенностей временных рядов рассмотрим их основные типы. Есть разные способы их классифицировать, рассмотрим некоторые из них [1].

1) По времени.

Можно выделить моментные и интервальные ряды.

Для формирования моментных рядов фиксируют значение показателя в определенный момент времени, а для интервальных уровень ряда сопоставляют с накопленным результатом за определенный интервал времени.

Например, ряд, состоящий из количества проданных цветов 8 марта является моментным (значения зафиксированы в конкретный день года), последовательность значений остатков денег на счету банковской карты на конец дня также формирует моментный ряд. Примерами интервальных рядов могут быть показатели объемов проданных товаров предприятия по дням, выпавших осадков за месяц в Санкт-Петербурге.

Основное отличие между моментными и интервальными рядами является то, что как правило суммировать показатели моментных рядов бессмысленно, чего нельзя сказать об интервальных рядах. Например, если взять ряд с остатками на счету банковской карты на конец дня (моментный ряд), то нет смысла складывать, это не принесет никакого осмысленного

показателя, но зато можно найти среднее, минимальное, максимальное значения, что уже может быть полезной информацией. А вот если сложить количество выпавших осадков за месяц в Санкт-Петербурге в течение 2025 года (интервальный ряд), то можно получить количество осадков в Санкт-Петербурге за весь год.

2) По форме представления уровней.

Бывают ряды абсолютных, относительных и средних величин.

3) По расстоянию между датами или интервалами времени.

В полных рядах наблюдения зафиксированы с равным интервалом во времени, в неполных же это условие не соблюдается.

1.2 Основные свойства и компоненты временного ряда

1.2.1 Компоненты временного ряда

В отличие от обычных выборок, временные

ряды обладают сложными характеристиками, такими как сезонность, цикличность, тренд, колебания, шум. Рассмотрим подробнее эти компоненты.

Сезонность представляет собой повторяющиеся изменения, происходящие через фиксированные регулярные интервалы или фиксированные периоды [2]. Часто в поведении людей можно наблюдать периодичность на ежедневном, еженедельном и годовом уровнях, что отражается на данных временного ряда. Например, если магазин цветов виден резкий рост в продажах, это не значит, что у них сработала рекламная компания, вероятно, наступил период праздников, а значит через пару дней показатели вернутся на прежний уровень.

Сезонные временные ряды могут называть периодическими временными рядами, но не все колебания имеют фиксированный период. Например, экономические циклы, сменный график работы, природные катаклизмы — это явления, у которых нет четкой сезонности, но прослеживается цикличность. Длительность цикла может меняться от одного проявления к другому.

Важной компонентой временного ряда является тренд или тенденция — плавное, долгосрочное изменение данных (рост, спад или стабильность), очищенное от случайных колебаний и сезонности.

Типы трендов есть самые разные, можно выделить основные, отражаемые в большей или меньшей степени линией тренда: прямолинейный, параболический, экспоненциальный, гиперболический, логарифмический и логистический тренды.

Во многих моделях считается, что временной ряд содержит случайные независимые значения с нулевым средним, постоянной дисперсией и отсутствием предсказуемой структуры — белый шум [3]. Его удобно рассматривать как внешний (экзогенный) шок, не коррелирующий с прошлым. Самый высокочастотный компонент. Случайные независимые значения с нулевым средним и постоянной дисперсией. Никакой предсказуемой структуры.

Также белый шум подразумевает постоянную колеблемость. Колеблемость представляет собой отклонения уровней отдельных периодов времени от тенденции динамики (тренда).

1.2.2 Иерархия тенденций и колебаний

Выше уже были описаны две важные компоненты временного ряда: тренд (тенденция) и колеблемость (колебания). Эти понятия описывают различные аспекты динамики ряда: долгосрочные изменения и случайные отклонения соответственно. При этом можно наблюдать такую вещь, как иерархию тенденций и колебаний: то, что для уровней высокого порядка выглядит как колебания, на интервале времени низшего порядка может являться тенденцией. Например, возьмем временной ряд, состоящий из показателей температуры воздуха подневно. Взяв данные за несколько лет, можно будет увидеть некий тренд, а с ним и колебания, которые на таком интервале не будут иметь сильного веса. Однако, если спуститься на уровень ниже и рассмотреть данные в рамках года, те самые колебания превращаются

в тренд: зимой температура ниже, весной растет, летом достигается пик, после осенью температура снова падает.

Эту особенность нужно также учитывать при прогнозах. Важно понимать какие изменения в рамках задачи являются критичными и должны восприниматься как тренд, а какие незначительны и можно принять за колебания, из этого вытекает масштаб, на котором должен производиться прогноз.

1.2.3 Сопоставимость уровней временных рядов

При формировании временного ряда важно помнить о таком условии, как сопоставимость уровней временных рядов. Это означает, что уровни ряда должны быть однородны по содержанию, иначе прогнозирование может быть некорректным за счет изменения сути или формата данных.

Статистические данные, представленные в виде временных рядов, должны быть сопоставимы:

1) По территории.

Например, хотим составить ряд со средней заработной платой граждан России по годам за последние 50 лет, но вопрос что считать за Россию? Ведь 50 лет назад был СССР с другими границами, а значит нельзя просто взять данные из СССР и сопоставить с тем, что были зафиксированы уже при России. Нужно обозначить территорию, для которой будет сформирован ряд, и учитывать только выбранные границы.

2) По кругу охватываемых объектов.

Уровни ряда за отдельные периоды должны учитывать один и тот же круг объектов.

Например, при подсчете населения России нельзя в один год учитывать только граждан РФ, а в другой год всех, включая эмигрантов.

3) По единицам измерения.

Очевидно, что некорректно сравнивать показатели, выраженные в разных единицах измерения. Можно составить временной ряд из значений роста детей некоторой школы, но данные записать для одних детей в метрах, а

для других в сантиметрах. Такой ряд анализировать будет бессмысленно, даже среднее значение не даст никакой информации.

4) По моменту регистрации.

Из-за сезонности нужно учитывать время регистрации. Если хотим составить ряд с ценой клубники по годам, то нужно выбрать за какую дату учитываем цену. Если в один год взять цену за 2 марта, а в другой за 2 июля, то разница выйдет колоссальная, хотя цены могли и не вырасти за год, просто повлияла сезонность.

Поэтому уровни при сравнении должны относиться к определенной дате ежегодно.

5) По методике расчета.

При определении сравниваемых уровней ряда необходимо использовать единую методику их расчета. Например, некоторая компания 10 лет считала выручку без вычета налогов, а после стала вычитать налоги. Значения, естественно, поменяются, в таком случае нужно либо оставить прошлый метод, либо старые значения пересчитать.

6) По ценам.

При анализе показателей в стоимостном выражении следует учитывать непрерывное изменение цен по множеству причин (инфляция, рост затрат и т.д.).

Один из способов обеспечения сопоставимости состоит в том, что продукцию, произведенную в разные периоды, либо оценивают в ценах одного периода или в сопоставимых ценах.

7) По достоверности.

Важно учитывать достоверность количественных и качественных характеристик изучаемых явлений. Это значит, что все уровни ряда (все цифры) должны быть измерены с одинаковой степенью точности и надежности. Различная репрезентативность выборки по периодам может сильно повлиять на результаты.

Например, в исследовании в первый месяц участвовали 1 000 человек, а в следующем 100. Вторая выборка менее достоверна, больше вероятность ошибки, ее нельзя сравнивать с первой выборкой. Или, например, в одной больнице измеряют температуру пациентам градусником с погрешностью результатов в 0.1°C , а во второй — с погрешностью в 5°C . Также сопоставлять такие данные нельзя, у второго градусника низкая достоверность.

Все вышеуказанные пункты стоит учитывать при формировании или подготовке временного ряда для корректного дальнейшего анализа и прогнозирования.

1.2.4 Стационарность, автокорреляция и лаговая структура

Временной ряд x_t называется стационарным [3], если:

- 1) $E x_t \equiv \text{const.}$
- 2) $\text{cov}(x_t, x_{t+h}) = \gamma(h).$

Это означает, что у ряда среднее значение временного ряда постоянно во времени, а значит отсутствует тренд. Также ковариация между разными элементами временного ряда зависит только от лага h . То есть если не от того, за какой момент времени рассматриваются значения, а от того, как далеко они друг от друга находятся.

Из-за простоты моделирования и фиксированных свойств во времени, стационарность является важным и необходимым свойством для многих моделей прогнозирования, в частности для классических, таких как ARIMA.

Временные ряды, которые не являются стационарными, называются нестационарными.

Упомянутая выше переменная h является лаговой переменной и характеризует разницу во времени между элементами временного ряда.

Функция $\gamma(h) = \text{cov}(x_t, x_{t+h})$ называется автоковариационной функцией временного ряда. Функция $\rho(h) = \text{corr}(x_t, x_{t+h})$ называется автокорреляционной функцией стационарного временного ряда. Она также,

как и автоковариационная функция зависит только от лага между элементами ряда.

Автокорреляция также является важным показателем при прогнозировании, особенно если используются модели временных рядов, поскольку она показывает зависимость между запаздывающими значениями временного ряда.

1.3 Подходы к прогнозированию временных рядов

На показатели временного ряда часто влияет множество внешних факторов, игнорирование которых может существенно снизить качество прогноза. Так можно выделить три метода прогнозирования, отличающиеся типом модели [4]:

1) Объяснительная модель.

Такая модель зависит от внешних переменных-предикторов, которые помогают объяснить причины колебаний значений ряда. Например, для прогноза урожая в модель будут подаваться показатели температуры, осадков, климатических условий, удобрений и т.п.

2) Модель временного ряда.

Здесь прогнозирование будущего основано на прошлых значениях переменной, а не на внешних переменных, которые могут повлиять на систему.

3) Смешанная модель.

Сочетание объяснительной модели и модели временного ряда.

Объяснительная модель полезна, поскольку учитывает внешние факторы, а не только исторические значения ряда. Однако есть причины, из-за которых выбирают модель временного ряда:

- не всегда понятно от каких внешних переменных зависит ряд либо сложно измерить взаимосвязь с рядом;
- часто для прогноза ряда нужно спрогнозировать показатели предикторов, что может быть тоже нетривиальной задачей;

- цель может заключаться именно в прогнозировании, а не в определении причин поведения параметров ряда определенным образом;
- в ряде случаев модели временных рядов могут обеспечивать более высокую точность прогноза, чем объяснительная или смешанная модель.

В рамках данной работы будет использован метод, при котором прогнозирование происходит за счет только моделей временных рядов, а значит внешние факторы не будут учтены.

1.4 Классические подходы к прогнозированию временных рядов

1.4.1 Общая характеристика классических методов прогнозирования временных

К классическим или традиционным методам прогнозирования временных рядов относят статистические подходы, в которых предполагается, что динамика данных из прошлого сохраняется в будущем. Они опираются на свойства и компоненты самого ряда, такие как уровни, тренд, сезонность [4].

Классические методы основаны на свойствах самого ряда, для них важна внутренняя структура данных, которую можно выявить, формализовать и использовать для построения прогноза. В зависимости от ряда его структура может описываться через автокорреляционные связи элементов, в других — через компоненты уровня, тренда и сезонности. Именно поэтому важным шагом при прогнозировании является предварительный анализ данных: исследование стационарности ряда (или степень близости к стационарности), поиск сезонности, цикличности, формы тренды [5].

Сильными сторонами классических методов являются интерпретируемость, экономия вычислительных ресурсов и понятная и прозрачная методология [5]. Благодаря этому можно понять на основе каких свойств и особенностей ряда модель выдала прогноз. Это особенно ценно в

прикладных исследованиях, где требуется после получения результата подкрепить и обосновать его.

Также традиционные модели не требуют столь больших объемов данных, как современные нейросетевые. Вместе с вычислительной экономичностью это дает классическим моделям сильное преимущество, причем не только при ограниченных ресурсах, но и в ситуациях, когда требуется получить быстрые и воспроизводимые расчеты.

При этом классические модели имеют и свои ограничения. Обычно они лучше работают на относительно стабильных и предсказуемых временных рядах, а при наличии сложных нелинейных зависимостей или быстро меняющейся динамики качество прогноза может снижаться [5].

Также важно учитывать, что классические методы прогнозирования не сводятся к одной конкретной модели. Существует несколько подходов к описанию временной структуры данных. В современной литературе чаще всего выделяют два крупных семейства [6]: модели экспоненциального сглаживания (ETS) и модели семейства ARIMA. Эти подходы по-разному описывают временной ряд: ETS делает акцент на уровне, тренде и сезонности, тогда как ARIMA больше ориентирована на внутренние зависимости между значениями ряда.

В данной работе эти два подхода рассматриваются на примере моделей ARIMA и Holt–Winters.

1.4.2 Модель ARIMA

Модель ARIMA является одной из наиболее известных классических моделей прогнозирования временных рядов. Она позволяет учитывать зависимость текущих значений ряда от прошлых наблюдений и ошибок прогноза, а также работать с рядами, которые изначально не являются стационарными [9].

Модель позволяет учитывать широкий круг временных зависимостей, оставаясь при этом интерпретируемой. Именно поэтому ARIMA часто

используется как одна из основных классических моделей в задачах сравнительного анализа методов прогнозирования.

Содержательно модель ARIMA основана на трёх идеях: авторегрессии, интегрировании и скользящем среднем. Благодаря авторегрессии учитывается влияние прошлых значений ряда на его текущее состояние. Интегрирование подразумевает под собой преобразование нестационарного ряда к более пригодному для прогноза виду. Скользящее среднее же позволяет учесть влияние прошлых ошибок. ARIMA позволяет формализовать зависимость между последовательными наблюдениями ряда, учитывая лаговые связи и влияние прошлых ошибок. Причем существенную роль играют не только лаговые зависимости, но и случайные отклонения, накопленные во времени.

Обычно модель указывают с параметрами, отражающие ее структуру в компактном виде: $ARIMA(p, d, q)$ [8]. Параметр p отвечает за авторегрессию, он задает количество предыдущих наблюдений, влияющих на текущее значение ряда. Параметр d показывает, сколько раз к ряду применяется операция дифференцирования, поскольку именно таким образом данные приводятся к более подходящему виду для моделирования, дифференцирование позволяет ослабить тренда и привести ряд к стационарности [9]. Параметр скользящего среднего q устанавливает количество лагированных ошибок, включаемых в модель.

Использование этих параметров помогает управлять моделью, определяя насколько глубоко будет учитываться память ряда и прошлые отклонения. Это означает, что выбор значений p , d и q является важной частью построения ARIMA-модели, поскольку от него напрямую зависит адекватность описания динамики временного ряда.

В отличие от двух других составляющих модели ARIMA, интегрированная часть может вызывать вопросы об ее необходимости, поэтому стоит прояснить этот момент. Считается, что авторегрессия и скользящее среднее работают корректно для рядов, свойства которых

существенно не меняются во времени. В реальности же ряды имеют тренды, сезонность, циклы или другие особенности, отдаляющие ряд от стационарности. Поэтому этап интегрирования так важен, без него оценки коэффициентов внутри модели будут смещёнными, а прогнозы могут оказаться недостоверными.

Сильной стороной модели ARIMA является ее способность достаточно компактно описывать динамику ряда ограниченным числом параметров. Модель позволяет учитывать как лаговые зависимости, так и нестационарность данных, при этом не усложняя их структуру. Также ARIMA является хорошим средством формализации временной динамики ряда за счет того, что она дает возможность проверки того, насколько хорошо выбранная модель описывает данные.

При использовании модели стоит учитывать и ее слабые стороны. ARIMA лучше работает с линейными зависимостями, поэтому она хуже справляется со сложными нелинейными закономерностями в данных. Помимо этого, ряд должен иметь возможность приводиться к стационарному виду с помощью преобразований.

Кроме того, на практике могут возникать проблемы при подборе параметров p , d и q , поскольку нет универсального правила как это делать. Наконец, модель предназначена прежде всего для одномерных рядов и внутренние временные связи, а значит возникнут проблемы при работе с данными, на которые сильно влияют внешние факторы.

1.4.3 Модель Holt–Winters

Среди классических методов прогнозирования временных рядов в семействе экспоненциального сглаживания модель Holt–Winters является наиболее известной. В отличие от простого экспоненциального сглаживания (требуется данные без тренда и сезонности), она применима к рядам, в которых одновременно присутствуют тренд и сезонность. Благодаря этой особенности модель стала одно из ключевых среди классических методов

прогнозирования и особенно часто используется в задачах краткосрочного и среднесрочного прогноза для данных с регулярной периодичностью [10].

Основная идея модели основана на трёх обновляемых компонентах временного ряда: уровень, тренд и сезонность. Для каждого нового наблюдения эти компоненты пересчитываются с помощью сглаживающих параметров и при этом учитывается накопленная информация о структуре ряда. Таким образом Holt–Winters на основе уровня описывает базовое положение ряда, с помощью тренда определяет направление и скорость изменения этого уровня, а сезонность помогает учесть повторяющиеся колебания. Модель запоминает и поддерживает актуальную внутреннюю структуру ряда и на основе этого делает прогноз.

Важной особенностью модели Holt–Winters является наличие двух ее вариантов: аддитивного и мультипликативного [11]. Аддитивная версия применяется, когда амплитуда сезонных колебаний не зависит от уровня, а значит не растет со временем. Мультипликативная же, напротив, используется, когда сезонный эффект изменяется пропорционально уровню, с течением времени сезонные отклонения увеличиваются. Поэтому перед прогнозом важно исследовать ряд на наличие сезонности и характер ее проявления. В противном случае модель может неправильно трактовать сезонность, что повлияет на качество результата.

Преимуществам модели Holt–Winters можно отнести ее простоту, интерпретируемость и применимость для рядов с выраженной сезонностью. Она не требует сложной настройки и дает возможность прозрачно объяснить какие компоненты повлияли на прогноз, что является полезным свойством для прикладных задач, где важно не только получить результат, но и обосновать его.

Однако, есть и слабые места. Модель рассчитана в первую очередь на ряды с регулярной сезонностью и плавной динамикой, поэтому сложные нелинейности, резкие структурные изменения или нестабильная сезонность могут привести к некачественному прогнозу. Также результат зависит от того,

насколько удачно проведена предварительная оценка ряда и далее выбран тип сезонной модели.

1.5 Нейросетевые подходы к прогнозированию временных рядов

1.5.1 Общая характеристика нейросетевых методов прогнозирования временных рядов

Нейросетевые методы прогнозирования временных рядов позволяют на основе обучаемых многослойных архитектур автоматически извлекать закономерности из данных. В отличие от классических статистических методов, где обычно заранее задается сравнительно узкий набор характеристик ряда, нейросетевые подходы являются более гибкими при обучении. Это объясняет их быстрое распространение, а рост вычислительных возможностей, развитие архитектур глубокого обучения и накопление больших массивов временных данных являются катализаторами для их развития [12].

Главное преимущество таких моделей заключается в способности выявлять сложные зависимости и закономерности, которые трудно описать классическими методами. Это особенно важно для временных рядов, где данные могут содержать не только тренд и сезонность, но и более сложные нелинейные связи. Кроме того, современные нейросетевые архитектуры способны работать как с одномерными, так и с многомерными временными рядами, автоматически выделяя значимые признаки без большого объема ручной настройки.

Тем не менее нейросетевые методы также имеют свои ограничения и не могут считаться универсальным решением для любых задач прогнозирования [13]. Во-первых, сложные архитектуры обычно требуют достаточного объема качественных данных, в противном случае возрастает риск переобучения и снижения устойчивости прогноза. Во-вторых, чем сложнее модель, тем сильнее увеличиваются вычислительные затраты, требования к настройке гиперпараметров и чувствительность к особенностям обучающей выборки. В-третьих, нейросетевые методы обычно менее интерпретируемы, чем

классические модели. Поэтому в академических и прикладных работах нейросетевые модели часто оцениваются не только по точности, но и по устойчивости, сложности настройки, количестве потребляемых ресурсов и интерпретируемости.

В рамках текущего исследования нейросетевые методы представляют интерес как современная группа моделей, потенциально способная лучше классических подходов работать со сложной структурой временных данных. Их включение в эксперимент позволяет проверить, насколько преимущества глубокого обучения действительно проявляются на выбранных рядах различной природы, и дают ли более сложные модели выигрыш по качеству прогноза в сопоставимых условиях. Поскольку обзор всех существующих нейросетевых архитектур выходит за рамки данной работы, далее рассматриваются два наиболее показательных подхода. Первый основан на последовательной обработке данных, второй представляет собой специализированную архитектуру для прогнозирования временных рядов. Поэтому далее внимание будет сосредоточено на моделях LSTM и N-BEATS.

1.5.2 Модель LSTM

Модель LSTM (Long Short-Term Memory) относится к рекуррентным нейронным сетям и предназначена для работы с последовательными данными [14]. В задачах прогнозирования временных рядов это особенно важно, поскольку текущее значение ряда часто зависит не только от последних наблюдений, но и от более далёких участков истории.

Перед рассмотрением LSTM стоит кратко описать принцип работы стандартной рекуррентной сети. В RNN на каждом шаге формируется скрытое состояние h_t , которое зависит от текущего входа x_t и предыдущего состояния h_{t-1} . В упрощенном виде это можно записать следующим образом:

$$h_t = \varphi(W_h h_{t-1} + W_x x_t + b),$$

где W_h и W_x — матрицы весов, b — смещение, а φ — функция активации, вводящая нелинейность в модель. Таким образом, скрытое состояние h_t можно

понимать как внутреннее представление информации о последовательности к текущему моменту времени: оно хранит то, что сеть "запомнила" после обработки предыдущих шагов. Таким образом RNN позволяет переносить информацию во времени, однако при длинных последовательностях такой памяти часто оказывается недостаточно.

Основная проблема обычных RNN связана с затуханием градиента при обучении модели [14]. Настройка параметров сети выполняется за счет минимизации функции потерь, для чего используется градиент, показывающий, как нужно изменять веса модели, чтобы уменьшить ошибку прогноза. В длинных последовательностях при передаче градиента к ранним шагам его величина уменьшается, поэтому сеть хуже обучается учитывать далекое прошлое. Из-за этого стандартные RNN испытывают трудности при моделировании долгосрочных зависимостей. Поэтому была предложена архитектура LSTM как способ ослабить это ограничение.

Основная идея LSTM состоит в том, что помимо скрытого состояния h_t модель использует отдельное состояние памяти C_t . Скрытое состояние отражает текущий выход сети, а память позволяет переносить значимую информацию через последовательность. Управление памятью осуществляется с помощью специальных ворот, которые определяют, что сохранить из прошлого, что забыть и что добавить из нового наблюдения. Благодаря этому LSTM лучше учитывает долгосрочные зависимости, чем обычная RNN.

На первом этапе LSTM определяет, какую часть предыдущей информации следует сохранить. Для этого используются ворота забывания:

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f),$$

где σ — сигмоидная функция, принимающая значения от 0 до 1. Если компонент f_t близок к нулю, соответствующая информация из предыдущего состояния памяти почти забывается; если он близок к единице, информация в значительной степени сохраняется. Иными словами, на этом шаге модель

решает, что из прошлого по—прежнему важно для дальнейшего прогноза, а что можно отбросить как менее значимое.

На следующем этапе модель определяет, какую новую информацию нужно записать в память. Для этого вычисляются входные ворота:

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i),$$

а также формируется набор новых кандидатных значений памяти

$$\tilde{C}_t = \tanh(W_c[h_{t-1}, x_t] + b_c).$$

Здесь i_t показывает, насколько сильно новая информация должна повлиять на память, а $\tilde{C}_t$ представляет собой новое содержимое, которое модель считает полезным добавить. По сути, на этом этапе LSTM отвечает на вопрос: что именно из текущего наблюдения важно запомнить для будущих шагов последовательности.

После этого происходит обновление состояния памяти:

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t,$$

где $\odot$ обозначает поэлементное умножение. Эта формула является центральной для всей архитектуры. Она показывает, что новая память C_t строится как сочетание двух частей: сохраненной информации из прошлого и новой информации, отобранной на текущем шаге. Благодаря такой схеме память в LSTM не заменяется полностью на каждом шаге, а обновляется постепенно. Это позволяет модели одновременно сохранять важную информацию из прошлого и учитывать новые данные.

На последнем этапе формируется текущее скрытое состояние сети:

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o),$$

$$h_t = o_t \odot \tanh(C_t).$$

Здесь o_t — выходные ворота, определяющие, какая часть текущего состояния памяти должна быть передана в скрытое состояние h_t . В результате выход сети зависит не только от текущего входа, но и от накопленной ранее информации. Благодаря этому LSTM хорошо подходит для задач, где важно учитывать долгосрочные зависимости внутри временного ряда.

В целом работу LSTM можно представить как последовательность нескольких этапов: удаление части старой информации, добавление новых данных, обновление памяти и формирование выхода. На практике модель обычно получает окно предыдущих наблюдений и на его основе прогнозирует следующее значение ряда или несколько будущих шагов. Именно поэтому LSTM широко используется в задачах прогнозирования временных рядов.

Однако у модели есть и ограничения. Для обучения LSTM обычно требуется достаточно большой объём данных, настройка гиперпараметров и заметные вычислительные ресурсы. Кроме того, по сравнению с классическими моделями такие сети хуже интерпретируются, поскольку внутреннюю логику полученного прогноза объяснить значительно сложнее. В рамках данной работы модель LSTM рассматривается как один из основных нейросетевых подходов для сравнения с классическими методами прогнозирования временных рядов.

1.5.3 Модель N-BEATS

Модель N-BEATS (Neural Basis Expansion Analysis for Interpretable Time Series Forecasting) относится к числу нейросетевых архитектур, специально разработанных для прогнозирования временных рядов [15]. В отличие от рекуррентных моделей, таких как LSTM, она не обрабатывает последовательность шаг за шагом, а работает сразу с целым окном прошлых наблюдений. Это делает модель особенно интересной для задач прогнозирования, поскольку ее архитектура изначально ориентирована именно на построение прогноза.

На вход N-BEATS обычно подается окно предыдущих наблюдений

$$x = [x_{t-n+1}, x_{t-n+2}, \dots, x_t],$$

где x — входной фрагмент ряда длины n . Цель модели состоит в том, чтобы по этому окну построить прогноз на будущий горизонт

$$y = [x_{t+1}, x_{t+2}, \dots, x_{t+H}],$$

где H — длина горизонта прогнозирования. Иными словами, модель должна по уже наблюдаемой части ряда предсказать его дальнейшее поведение.

Архитектура N-BEATS строится из нескольких последовательно соединённых блоков. Под блоком в данном случае понимается отдельный вычислительный модуль нейросети, который получает на вход текущее представление временного ряда и обрабатывает его с помощью полносвязных слоёв. Использование блоков позволяет модели не пытаться описать весь временной ряд за один шаг, а выделять его структуру постепенно. Благодаря этому каждый блок объясняет часть входного сигнала и вносит собственный вклад в итоговый прогноз, а следующие блоки уточняют результат, работая с оставшейся необъяснённой частью ряда [15].

На выходе каждого блока формируются две части:

$$\begin{aligned}\hat{x}^{(r)} &= \textit{backcast}^{(r)}, \\ \hat{y}^{(r)} &= \textit{forecast}^{(r)},\end{aligned}$$

где r — номер блока. Компонента *backcast* описывает часть входного сигнала, которую текущий блок смог объяснить, а *forecast* отвечает за вклад блока в итоговый прогноз. Иными словами, *backcast* помогает модели разобраться с уже наблюдаемым участком ряда, а *forecast* отвечает за предсказание будущих значений.

После этого следующему блоку передаётся не исходный сигнал, а оставшийся остаток:

$$x^{(r+1)} = x^{(r)} - \hat{x}^{(r)}$$

В этом заключается одна из основных идей N-BEATS: каждый следующий блок работает только с той частью ряда, которую предыдущие блоки ещё не смогли описать. За счёт этого модель постепенно уточняет прогноз. Итоговый результат формируется как сумма прогнозов всех блоков:

$$\hat{y} = \sum_{r=1}^R \hat{y}^{(r)},$$

где R — число блоков.

Таким образом, N-BEATS строит прогноз поэтапно: каждый блок выделяет часть закономерностей ряда и передаёт дальше только необъяснённый остаток. В отличие от LSTM, модель не использует рекуррентные переходы и явную память, а работает за счёт последовательной обработки входного окна несколькими блоками полносвязных слоёв.

Одной из особенностей N-BEATS является наличие интерпретируемой версии архитектуры, в которой отдельные блоки могут описывать тренд и сезонность. Это делает модель ближе к классическим подходам к анализу временных рядов.

На практике N-BEATS использует входные окна фиксированной длины и применяется для прогноза одного или нескольких будущих значений. К ее достоинствам относят высокое качество прогнозирования и специализированность именно под задачу прогнозирования. Однако модель остается глубокой нейросетевой архитектурой, поэтому требует настройки гиперпараметров, достаточного объема данных и вычислительных ресурсов. В рамках настоящего исследования N-BEATS рассматривается как специализированный нейросетевой подход, дополняющий модель LSTM.

1.6 Метрики оценки качества прогнозирования временных рядов

В задачах прогнозирования временных рядов метрики качества необходимы для количественной оценки результатов модели. Визуальное сходство графика прогноза с реальным рядом еще не означает высокой точности на новых данных. Поэтому качество модели следует оценивать по ошибкам прогноза на наблюдениях, которые не использовались при обучении. В этом смысле метрики являются важной частью методологии исследования, поскольку именно они позволяют формально судить о качестве прогноза.

Метрики особенно важны в сравнительных исследованиях, где необходимо сопоставить несколько моделей в одинаковых условиях. Без формализованных критериев невозможно надежно определить, какая модель действительно работает лучше. При этом одной метрики обычно

недостаточно, поскольку разные показатели по-разному реагируют на ошибку прогноза. Например, одни метрики удобны для оценки абсолютной ошибки, другие — для относительной, а некоторые могут вести себя нестабильно при малых или нулевых значениях ряда. Поэтому выбор метрик влияет не только на оценку качества, но и на интерпретацию итоговых результатов.

В рамках исследования для оценки выбраны следующие метрики:

1) MAE.

Метрика MAE (Mean Absolute Error, средняя абсолютная ошибка) показывает, насколько в среднем прогноз модели отличается от реальных значений. Она вычисляется по формуле:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|,$$

где y_i — фактическое значение, $\hat{y}_i$ — прогнозное значение, n — число наблюдений.

Эта метрика показывает среднюю величину ошибки без учета знака, то есть неважно, завышает модель прогноз или занижает. Главное насколько далеко прогноз находится от реального значения.

Интерпретировать MAE удобно, потому что она измеряется в тех же единицах, что и сам временной ряд. Например, если MAE=5, это означает, что модель в среднем ошибается примерно на 5 единиц.

Особенность MAE состоит в том, что она одинаково учитывает все ошибки. Поэтому метрика хорошо подходит для общей оценки точности, но не выделяет крупные промахи сильнее остальных.

В данной работе MAE используется как дополнительная метрика, позволяющая оценить среднюю абсолютную ошибку прогноза для каждой модели.

2) RMSE.

Метрика RMSE (Root Mean Squared Error, корень из средней квадратичной ошибки) также используется для оценки средней ошибки

прогноза, однако она сильнее реагирует на крупные отклонения. Формула метрики имеет вид:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2},$$

При вычислении RMSE ошибки сначала возводятся в квадрат, затем усредняются, после чего из полученного значения извлекается корень. Возведение в квадрат усиливает влияние больших ошибок, а извлечение корня позволяет вернуть результат к тем же единицам измерения, что и исходный ряд. Поэтому крупные отклонения влияют на RMSE заметно сильнее, чем небольшие.

Интерпретация метрики достаточно проста. Например, если $RMSE=8$, это означает, что средняя ошибка прогноза с учетом крупных отклонений составляет около 8 единиц.

Основная особенность RMSE заключается в высокой чувствительности к большим ошибкам. Поэтому данная метрика особенно полезна в случаях, когда важно учитывать не только средний уровень ошибки, но и наличие сильно неудачных прогнозов.

В рамках данной работы RMSE используется как базовая метрика, позволяющая оценить склонность модели к крупным ошибкам.

3) sMAPE

Метрика sMAPE (Symmetric Mean Absolute Percentage Error, симметричная средняя абсолютная процентная ошибка) показывает среднюю ошибку прогноза в процентном выражении. Она рассчитывается следующим образом:

$$sMAPE = \frac{100\%}{n} \sum_{i=1}^n \frac{2|y_i - \hat{y}_i|}{|y_i| + |\hat{y}_i|}$$

В отличие от абсолютных метрик, sMAPE оценивает ошибку относительно масштаба значений ряда. По сравнению с MAPE эта метрика

считается более устойчивой, так как в знаменателе используются одновременно фактические и прогнозные значения. Благодаря этому sMAPE обычно работает стабильнее на рядах с малыми значениями.

Интерпретировать sMAPE также достаточно удобно: она показывает, на сколько процентов прогноз в среднем отличается от реальных значений. Например, значение $sMAPE=10\%$ означает, что среднее относительное отклонение прогноза составляет около 10 процентов.

При этом, как и другие относительные метрики, sMAPE требует аккуратной интерпретации. Тем не менее в задачах сравнительного анализа она часто оказывается удобнее MAPE, если требуется использовать процентную оценку ошибки.

В данной работе sMAPE используется как относительная метрика, дополняющая абсолютные показатели MAE и RMSE.

Использование метрик делает оценку результатов более понятной и объективной. MAE, RMSE и sMAPE широко применяются благодаря относительной простоте вычисления и интерпретации. Вместе с тем каждая из этих метрик характеризует ошибку прогноза по-своему, поэтому использование только одного показателя может дать неполную оценку качества модели. По этой причине в сравнительных исследованиях обычно применяют несколько метрик одновременно. Это позволяет не только измерить ошибку прогноза, но и более корректно сопоставить результаты разных моделей.

1.7 Выводы по главе

В первой главе были рассмотрены теоретические основы прогнозирования временных рядов. Проведенный анализ показал, что временные ряды представляют собой особый тип данных, при работе с которым важно учитывать не только сами значения показателя, но и их связь во времени. В отличие от обычных выборок, здесь существенную роль играют тренд, сезонность, колебания, автокорреляция и стационарность. Кроме того, было показано, что для корректного анализа и прогнозирования большое

значение имеет сопоставимость данных, поскольку ошибки на этапе подготовки ряда могут повлиять на результаты всей дальнейшей работы.

Также в данной главе были рассмотрены основные подходы к прогнозированию временных рядов. Это позволило показать, что для решения подобных задач могут использоваться разные типы моделей, однако в рамках настоящей работы основной интерес представляют именно модели временных рядов, строящие прогноз на основе прошлых значений самого ряда. Такой подход соответствует цели исследования и позволяет сосредоточиться на сравнении методов, использующих внутреннюю структуру данных без учета внешних факторов.

Отдельное внимание было уделено классическим моделям прогнозирования. Рассмотрение моделей ARIMA и Holt–Winters показало, что классические методы по-прежнему остаются важным инструментом анализа временных рядов благодаря понятной логике работы, интерпретируемости и относительно невысоким вычислительным требованиям. При этом модели используют разные принципы построения прогноза: ARIMA ориентируется на внутренние зависимости и лаговую структуру ряда, а Holt–Winters — на уровень, тренд и сезонность. Это делает их обоснованной базой для дальнейшего сравнения.

Далее были рассмотрены нейросетевые методы прогнозирования временных рядов. Анализ моделей LSTM и N-BEATS показал, что современные нейросетевые архитектуры способны учитывать более сложные зависимости в данных и обеспечивают большую гибкость при построении прогноза. Вместе с тем такие модели обычно требуют большего объема данных, более тщательной настройки и значительных вычислительных ресурсов. Таким образом, было показано, что классические и нейросетевые подходы различаются не только по сложности, но и по самой логике прогнозирования, что делает их сравнительный анализ актуальным.

Также в главе были рассмотрены метрики оценки качества прогнозирования. Это позволило показать, что сравнение моделей не может

основываться только на визуальном анализе графиков, поскольку для корректной оценки необходимы количественные критерии. В работе используются метрики MAE, RMSE и sMAPE, так как они позволяют оценивать качество прогноза с разных сторон: через среднюю абсолютную ошибку, чувствительность к крупным отклонениям и относительную процентную ошибку. Использование нескольких метрик одновременно делает дальнейший анализ более надежным и позволяет более корректно сравнивать модели между собой.

Таким образом, в первой главе была сформирована теоретическая основа исследования. Были рассмотрены особенности временных рядов, подходы к их прогнозированию, классические и нейросетевые модели, а также метрики оценки качества. Это создает необходимую базу для перехода ко второй главе, где будет описан вычислительный эксперимент: выбор данных, их подготовка, реализация моделей, проведение сравнения и анализ полученных результатов. Иными словами, первая глава подводит теоретическую основу для всей практической части работы.

2 Методика и проведение вычислительного эксперимента

2.1 Дизайн вычислительного эксперимента

Целью вычислительного эксперимента является проведение сравнительного анализа классических и нейросетевых моделей прогнозирования временных рядов в одинаковых и сопоставимых условиях. Эксперимент строится таким образом, чтобы оценить не только точность прогнозирования, но и вычислительные и практические особенности различных подходов к прогнозированию временных рядов [16].

В рамках работы рассматриваются две группы моделей прогнозирования временных рядов:

- классические модели: ARIMA и Holt-Winters;
- нейросетевые модели: LSTM и N-BEATS;
- базовая модель: Naïve baseline.

Помимо основных моделей прогнозирования, в эксперимент дополнительно включается базовая модель Naïve baseline [17]. В данной модели каждое новое значение прогноза принимается равным последнему доступному наблюдению ряда. Такая baseline-модель используется как простая отправная точка для сравнения и позволяет оценить, насколько более сложные методы действительно улучшают качество прогнозирования по сравнению с базовым инерционным подходом.

Для обеспечения корректности сравнительного анализа в эксперимент включены временные ряды с различными характеристиками. Используются несколько независимых одномерных рядов, отличающихся предметной областью, частотой наблюдений, продолжительностью, масштабом значений, выраженностью сезонности, уровнем шума и особенностями временной динамики.

Такой выбор данных позволяет проверить работу моделей в разных условиях и сделать результаты исследования менее зависимыми от специфики отдельного датасета.

В рамках работы рассматриваются только одномерные временные ряды. Дополнительные внешние факторы и экзогенные признаки в эксперимент не включаются. Это позволяет сосредоточиться именно на сравнении моделей прогнозирования и сохранить одинаковые условия для всех рассматриваемых подходов.

Для всех моделей используется единая схема проведения эксперимента: данные → предобработка → разделение данных → обучение модели → → прогнозирование → расчёт метрик → сравнительный анализ ,

Разделение данных выполняется строго с сохранением временного порядка наблюдений без случайного перемешивания данных. Для каждого временного ряда используются три выборки:

- обучающая выборка (train) — 80%;
- валидационная выборка (validation) — 10%;
- тестовая выборка (test) — 10%.

Обучающая выборка используется для обучения моделей. Валидационная выборка применяется для ограниченного подбора гиперпараметров и выбора конфигурации модели. После подбора параметров модель обучается повторно на объединённых train и validation данных, а затем оценивается на test выборке.

В работе рассматриваются два режима прогнозирования: рекурсивное многошаговое прогнозирование (recursive multi-step forecasting) и пошаговое прогнозирование с использованием реальных наблюдений (walk-forward forecasting).

При рекурсивном прогнозировании модель на каждом шаге предсказывает следующее значение ряда, после чего собственный прогноз используется как часть входных данных для следующего шага. Такой подход позволяет оценить влияние накопления ошибок на длинном горизонте прогнозирования.

В режиме walk-forward модель также выполняет прогноз только на один шаг вперёд, однако после каждого шага в историю добавляется уже реальное значение из тестовой выборки. Это позволяет оценить качество одношагового прогнозирования без накопления ошибок предыдущих прогнозов.

Использование двух схем прогнозирования позволяет сравнить поведение моделей как в условиях длинного автономного прогноза, так и в условиях последовательного обновления информации о временном ряде.

Горизонт прогнозирования определяется длиной тестового интервала и может различаться для разных временных рядов из-за различной длины и частоты данных.

Для оценки качества прогнозирования используются следующие метрики:

- RMSE — в качестве основной метрики;
- MAE;
- sMAPE.

Использование нескольких метрик позволяет учитывать разные аспекты качества прогноза, включая среднюю величину ошибки, чувствительность к крупным ошибкам и относительную ошибку прогнозирования.

Для обеспечения сопоставимости результатов все модели оцениваются:

- на одинаковых временных рядах;
- при одинаковой схеме разделения данных;
- с использованием одинаковых метрик качества;
- в рамках единой процедуры обучения и тестирования.

Настройка моделей выполняется в формате ограниченного подбора гиперпараметров (controlled tuning) [18]. Для каждой модели используется заранее определённый набор допустимых конфигураций параметров. Глубина настройки поддерживается примерно одинаковой между моделями, что позволяет избежать ситуации, при которой отдельные модели получают преимущество только за счёт более сложной настройки.

Целью настройки является получение корректных рабочих конфигураций моделей, а не проведение максимально глубокой оптимизации гиперпараметров.

Помимо точности прогнозирования в работе дополнительно анализируются вычислительные и практические характеристики моделей. В частности, рассматриваются:

- время обучения моделей;
- время построения прогноза;
- вычислительные затраты;
- устойчивость качества прогнозирования на различных временных рядах;
- требования моделей к длине временного ряда;
- сложность настройки моделей;
- интерпретируемость моделей.

Для количественных критериев сравнения используется нормализация значений внутри каждого датасета с последующим усреднением результатов между временными рядами. Нормализованные значения переводятся в шкалу от 0 до 5)

Для качественных критериев, таких как интерпретируемость и сложность настройки, используются экспертные оценки на основе заранее определённой шкалы.

Устойчивость качества прогнозирования рассматривается как общий показатель модели, отражающий стабильность результатов на различных временных рядах. В качестве основы оценки устойчивости используется разброс рангов или нормализованных оценок качества между различными датасетами.

Итоговый анализ результатов включает несколько этапов:

- анализ значений метрик качества прогнозирования;
- ранжирование моделей на различных временных рядах;

- сравнение вычислительных затрат;
- формирование многокритериального профиля моделей.

Для наглядного представления структуры вычислительного эксперимента на рисунке 1 приведена общая схема проведения исследования.




Рисунок 1 – Общая схема вычислительного эксперимента

Схема отражает основные этапы эксперимента: подготовку данных, разделение временных рядов на выборки, обучение моделей, построение прогнозов, расчёт метрик качества и проведение сравнительного анализа результатов.

Для обеспечения воспроизводимости результатов фиксируются параметры эксперимента, random seed генераторов случайных чисел и сохраняются результаты работы моделей. Кроме того, реализуется единый программный pipeline вычислительного эксперимента.

2.2 Используемые данные

Для проведения вычислительного эксперимента в работе выбраны четыре одномерных временных ряда различной природы. Такой выбор

позволяет проверить поведение классических и нейросетевых моделей не на одном узком типе данных, а на нескольких рядах, различающихся по предметной области, частоте наблюдений и типу показателя. В соответствии с общей логикой исследования в набор включены один экономический и три неэкономических датасета. Это делает сравнение моделей более содержательным и позволяет оценить, насколько устойчиво они работают на данных с разной структурой.

Первым датасетом выбран ряд Unemployment Level (далее – ряд Unemploy) [19], отражающий численность безработных в США. Это экономический временной ряд с месячной частотой наблюдений. Показатель представлен в абсолютных значениях и измеряется в тысячах человек. Данный ряд включён в исследование как пример социально-экономического показателя, на динамику которого могут влиять макроэкономические процессы, кризисные явления и сезонные факторы.

Второй датасет представляет собой ряд температуры воздуха в 12:00 по станции города Прага (станция №11518) (далее — ряд Temperature) [20]. Это метеорологический временной ряд с дневной частотой, сформированный из почасовых наблюдений путём отбора значений в фиксированный момент суток. Включение данного ряда позволяет рассмотреть данные природного происхождения, для которых характерны регулярные колебания и выраженная сезонность. Кроме того, такой датасет удобен для сопоставления моделей на относительно понятной и интерпретируемой динамике.

Третий датасет — ряд Daily Bike Sharing Demand (далее — ряд Bike) [21], то есть дневное количество аренд велосипедов. Это временной ряд с дневной частотой наблюдений, который показывает количество аренд велосипедов за день. Данный ряд интересен тем, что в нём присутствуют сезонность, изменения спроса и локальные колебания. Его использование позволяет проверить, как модели работают с данными о повседневной активности пользователей.

Четвёртым датасетом выбран ряд Weekly weighted ILI percentage (далее — ряд ILI) по США [22]. Он относится к медицинской и эпидемиологической области и представляет собой недельный относительный показатель — долю амбулаторных визитов, связанных с гриппоподобными заболеваниями. Включение этого ряда в эксперимент важно по двум причинам. Во-первых, он отличается от остальных датасетов по смыслу и частоте наблюдений. Во-вторых, он представляет собой не абсолютное значение, а относительную величину, что делает итоговый набор данных более разнообразным.

Таким образом, выбранный набор датасетов охватывает несколько различных предметных областей: экономику, метеорологию, естественно-научные наблюдения и медицинский мониторинг. Кроме того, в исследование включены ряды с разной частотой — месячной, дневной и недельной, а также с разным типом показателя — абсолютным, индексным и относительным. Такой подход соответствует цели работы и создаёт основу для более универсального сравнительного анализа моделей прогнозирования временных рядов.

2.3 Предобработка данных

На этапе предобработки все выбранные временные ряды были приведены к единому формату. Для каждого датасета были оставлены две основные колонки: дата наблюдения (date) и значение целевой переменной (target). Колонка с датой была приведена к типу `datetime64[ns]`, а целевая переменная — к числовому типу данных (`float64/int64`).

Для обеспечения корректности дальнейшего анализа была выполнена проверка пропусков, дубликатов дат и некорректных значений. Обнаруженные пропуски и служебные значения, обозначающие отсутствующие наблюдения, были удалены. Также была выполнена сортировка данных по дате и проверка равномерности временного шага.

После предобработки все временные ряды были сохранены в отдельные очищенные файлы. Это позволяет использовать единые подготовленные

версии данных на следующих этапах эксперимента и обеспечивает воспроизводимость вычислений.

Основные характеристики временных рядов после предобработки представлены в таблицах 1-2.

Таблица 1 — Общая характеристика временных рядов после предобработки

Датасет	Наблюдений	Начало	Конец	Шаг
Unemploy	939	1948-01-01	2026-03-01	1 месяц
Temperature	4383	2014-01-01	2025-12-31	1 день
Bike	731	2011-01-01	2012-12-31	1 день
ILI	1228	2002-09-30	2026-04-06	7 дней

Таблица 2 — Статистические характеристики рядов после предобработки

Датасет	Мин.	Макс.	Среднее.	Ст. откл.
Unemploy	1596	23084	6609.058	3019.914
Temperature	-10.8	34.5	12.972	8.911
Bike	22	8714	4504.349	1937.211
ILI	0.352	8.28	2.034	1.433

В приложении А к диплому можно найти рисунки А.1-А.4 с графиками временных рядов. Они позволяют визуально оценить динамику показателей, наличие тренда, сезонности, резких изменений и возможных аномальных участков.

После очистки каждый временной ряд разделяется на три части с сохранением временного порядка наблюдений:

- обучающая выборка — 80%;
- валидационная выборка — 10%;
- тестовая выборка — 10%.

Для классических моделей данные используются в исходном масштабе. Для нейросетевых моделей дополнительно выполняется нормализация значений целевой переменной. При этом параметры нормализации

рассчитываются только на обучающей выборке, после чего применяются к валидационной и тестовой выборкам. Такой подход позволяет избежать утечки информации из будущих данных. Нормализованные данные были сохранены в отдельных файлах.

2.4 Реализация вычислительного эксперимента

Реализация эксперимента выполнялась на языке Python в формате Jupyter Notebook. Для обработки данных использовались библиотеки pandas и numpy, для классических моделей — statsmodels, для нейросетевых моделей — TensorFlow/Keras, для визуализации — plotly.

Все временные ряды были заранее приведены к единому формату: date, target.

Для каждого ряда запускались одни и те же модели: Naive baseline, ARIMA, Holt-Winters, LSTM и N-BEATS. Для каждой модели сохранялись прогноз, выбранные параметры, значения метрик качества, время обучения и время построения прогноза.

Модель Naive baseline использовалась как простой ориентир. Для неё параметры не подбирались: прогноз строился как повторение последнего известного значения временного ряда.

Для модели ARIMA подбирались параметры p , d и q . В эксперименте использовались следующие значения:

$$p \in \{0, 1, 2, 3, 4\},$$

$$d \in \{0, 1, 2\},$$

$$q \in \{0, 1, 2, 3, 4\}.$$

Такой диапазон позволяет проверить несколько конфигураций модели разной сложности, но не делает подбор слишком долгим. Остальные параметры реализации ARIMA оставались стандартными для библиотеки statsmodels.

Для модели Holt-Winters подбирались следующие параметры:

- тип тренда: без тренда, аддитивный, мультипликативный;

- тип сезонности: без сезонности, аддитивная, мультипликативная;
- наличие затухающего тренда;
- длина сезонного периода.

Мультипликативные варианты использовались только для рядов с положительными значениями. Сезонные периоды задавались с учётом частоты ряда: для Unemploy рассматривались 6 и 12, для Temperature и Bike — 7, 14, 30 и 365, для ILI — 26 и 52. Также для каждого ряда проверялся вариант без сезонности. Внутренние коэффициенты сглаживания отдельно не задавались, а оценивались автоматически средствами statsmodels [23]. Метод инициализации был зафиксирован как estimated.

Для нейросетевых моделей данные дополнительно масштабировались с помощью MinMaxScaler [24]. Параметры масштабирования рассчитывались только на обучающей выборке. После построения прогноза выполнялось обратное преобразование, поэтому метрики считались в исходном масштабе ряда.

Для LSTM и N-BEATS ряд преобразовывался в набор скользящих окон. Основным подбираемым параметром была длина входного окна. Она выбиралась с учётом частоты ряда:

$$W_{monthly} = \{6, 12, 24\},$$

$$W_{weekly} = \{4, 12, 24\},$$

$$W_{daily} = \{7, 14, 30\}.$$

Для LSTM дополнительно подбирался размер скрытого слоя:

$$hidden_size \in \{32, 64\}.$$

Остальные параметры LSTM были зафиксированы:

- количество LSTM-слоёв — 1;
- число эпох — 20;
- размер батча — 32;
- скорость обучения — 0.001;
- оптимизатор — Adam;

- функция потерь — MSE.

Эти значения были выбраны как базовые и достаточно устойчивые для небольших одномерных рядов. Увеличение числа слоёв или эпох не использовалось, поскольку целью работы является сопоставимое сравнение моделей, а не глубокая оптимизация одной архитектуры.

Для N-BEATS подбирались длина входного окна и размер скрытых слоёв:

$$hidden_size \in \{64, 128\}.$$

Остальные параметры N-BEATS также фиксировались:

- количество блоков — 2;
- количество слоёв внутри блока — 2;
- число эпох — 20;
- размер батча — 32;
- скорость обучения — 0.001;
- оптимизатор — Adam;
- функция потерь — MSE.

Фиксация части параметров позволила сократить время эксперимента и сохранить одинаковую глубину настройки между моделями. Подбор выполнялся только для тех параметров, которые сильнее всего влияют на способность модели учитывать прошлые значения ряда: длины окна и размера скрытого представления.

В программной реализации для каждой модели были сделаны два варианта построения прогноза: Recursive и WF. Для этого в коде использовались отдельные функции прогнозирования, но обучение и подбор параметров модели оставались одинаковыми. Это позволило сравнить влияние способа построения прогноза без изменения самой модели.

В итоговых таблицах результаты сохранялись отдельно для каждого режима. Например, для одной и той же модели формировались две строки: ARIMA-Recursive и ARIMA-WF, LSTM-Recursive и LSTM-WF. Такой формат

позволил отдельно анализировать качество длинного автономного прогноза и качество пошагового прогноза.

После реализации моделей был выполнен полный запуск эксперимента для всех выбранных временных рядов. Для каждого датасета последовательно запускались Naïve baseline, ARIMA, Holt-Winters, LSTM и N-BEATS в двух режимах прогнозирования: Recursive и WF. По итогам работы каждой модели сохранялись прогнозные значения, значения метрик RMSE, MAE и sMAPE, выбранные параметры и время выполнения. Далее эти результаты использовались для построения итоговых таблиц и графиков, приведённых в следующем разделе.

3 Анализ результатов вычислительного эксперимента

3.1 Общие результаты эксперимента

После проведения вычислительного эксперимента были получены результаты прогнозирования для всех рассматриваемых моделей на четырёх временных рядах: Unemploy, Temperature, Bike и ILI. Для каждого датасета модели тестировались в двух режимах прогнозирования: recursive forecasting и walk-forward forecasting. Две таблицы В.1-В.2 полных результатов, включающие значения метрик RMSE, MAE, sMAPE, параметры моделей и время выполнения, приведены в приложении В.

Для первичного анализа были выделены лучшие модели на каждом временном ряде отдельно для каждого режима прогнозирования. В таблице 3 представлены лучшие результаты для recursive forecasting.

Таблица 3 — Лучшие модели в режиме recursive forecasting на полном тестовом интервале

Ряд	Лучшая модель	RMSE	MAE	sMAPE
Unemploy	Naive-Recursive	3285.934	1545.372	17.390
Temperature	ARIMA-Recursive	8.916	7.554 73	73.171
Bike	N-BEATS-Recursive	1670.774	1192.801	30.618
ILI	Holt-Winters-Recursive	1.240	0.870	26.390

Результаты показывают, что в режиме recursive forecasting ошибки остаются достаточно высокими для всех рядов. Особенно это заметно по метрике sMAPE: для Temperature она составляет 73.171%, для Bike — 30.618%, для ILI — 26.390%.

Даже для ряда Unemploy, где лучшей оказалась модель Naive-Recursive, значения ошибок остаются большими: $RMSE = 3285.934$ и $MAE = 1545.372$. Это показывает, что более сложные модели в данном случае не смогли заметно улучшить качество прогноза по сравнению с baseline-подходом.

В целом результаты recursive forecasting показывают, что при прогнозировании длинного горизонта ошибка начинает постепенно

накапливаться, из-за чего прогноз всё сильнее отклоняется от реальных значений ряда.

В таблице 4 представлены лучшие результаты для режима walk-forward forecasting.

Таблица 4 — Лучшие модели в режиме walk-forward forecasting на полном тестовом интервале

Ряд	Лучшая модель	RMSE	MAE	sMAPE
Unemploy	Naive-WF	1748.220	475.670	4.450
Temperature	ARIMA-WF	3.175	2.417	43.387
Bike	Naive-WF	1332.242	930.838	28.115
ILI	N-BEATS-WF	0.390	0.255	7.297

Сравнение результатов показывает, что режим walk-forward forecasting в целом даёт более низкие ошибки, чем recursive forecasting. Для всех четырёх рядов лучшие значения RMSE в режиме WF оказались ниже. Например, для Unemploy RMSE уменьшается с 3285.934 до 1748.220, для Temperature — с 8.916 до 3.175, для Bike — с 1670.774 до 1332.242, а для ILI — с 1.240 до 0.390.

Это связано с тем, что в режиме walk-forward forecasting после каждого шага в историю добавляется фактическое значение ряда, а не предыдущее предсказание модели. За счёт этого ошибка не накапливается так быстро.

При этом даже в режиме WF качество прогнозирования остаётся неравномерным. Для ряда Temperature значение sMAPE составляет 43.387%, а для Bike — 28.115%. Это показывает, что даже лучшие модели испытывают сложности на отдельных временных рядах.

Также стоит отметить, что для рядов Unemploy и Bike лучшей моделью в режиме WF оказалась Naive-WF. Это говорит о том, что для некоторых рядов простое повторение последнего значения оказывается достаточно сильным baseline-подходом.

Для дополнительного анализа были рассмотрены графики прогнозирования для различных режимов работы моделей.

На рисунке 2 представлен пример удачного прогнозирования в режиме walk-forward forecasting для ряда ILI с использованием модели LSTM.




Рисунок 2 – Предсказание LSTM для ряда ILI в режиме walk-forward

Можно заметить, что модель достаточно хорошо повторяет как общую динамику ряда, так и локальные изменения значений. Прогноз остаётся близким к фактическим значениям на протяжении всего тестового интервала.

На рисунке 3 представлен пример recursive forecasting для ряда ILI с использованием модели Holt-Winters.




Рисунок 3 – Предсказание Holt-Winters для ряда ILI в режиме recursive

Несмотря на использование recursive forecasting, модель всё ещё сохраняет общую структуру ряда и основные сезонные колебания. Однако

прогноз становится более сглаженным и постепенно начинает терять часть локальных особенностей временного ряда.

На рисунке 4 представлен пример неудачного recursive forecasting для ряда Bike с использованием модели LSTM.




Рисунок 4 – Предсказание LSTM для ряда Bike в режиме recursive

По мере увеличения горизонта прогнозирования модель начинает всё сильнее отклоняться от реальной динамики ряда. Прогноз становится чрезмерно сглаженным и в отдельных участках практически превращается в прямую линию.

Таким образом, визуальный анализ подтверждает результаты метрик качества: на длинном горизонте recursive forecasting качество прогнозирования часто заметно ухудшается.

Для проверки влияния горизонта прогнозирования был дополнительно проведён анализ качества моделей только на первых 10% тестового интервала.

В таблице 5 представлены лучшие результаты моделей в режиме recursive forecasting на первых 10% тестовой выборки.

Результаты показывают, что при уменьшении горизонта прогнозирования качество recursive forecasting заметно улучшается практически для всех рядов.

Таблица 5 — Лучшие модели в режиме recursive forecasting на первых 10% тестового интервала

Ряд	Лучшая модель	RMSE	MAE	sMAPE
Unemploy	Naive-Recursive	150.999	115.889	1.849
Temperature	ARIMA-Recursive	2.705	2.094	35.177
Bike	LSTM-Recursive	755.934	525.381	7.673
ILI	Holt-Winters-Recursive	0.485	0.321	6.079

Наиболее сильное улучшение наблюдается для Bike: RMSE уменьшается с 1670.774 до 755.934, а sMAPE — с 30.618% до 7.673%. Для Unemploy RMSE снижается более чем в 20 раз: с 3285.934 до 150.999.

Даже для Temperature, где на полном тестовом интервале ошибки оставались высокими, качество прогноза на коротком участке становится заметно лучше.

Интересно, что на коротком горизонте нейросетевые модели начинают чаще показывать лучшие результаты. Например, для Bike лучшей моделью становится LSTM-Recursive.

Далее рассмотрим результаты моделей отдельно для каждого временного ряда.

1) Ряд Unemploy

Для ряда Unemploy наиболее устойчивые результаты среди основных моделей показала ARIMA-WF:

- RMSE = 1794.160;
- MAE = 500.540;
- sMAPE = 4.510%.

Близкие результаты показала Holt-Winters-WF:

- RMSE = 1748.220;
- MAE = 475.670;
- sMAPE = 4.450%.

Нейросетевые модели показали более высокие ошибки:

- N-BEATS-WF: RMSE = 2155.680;
- LSTM-WF: RMSE = 2740.940.

На коротком тестовом интервале ошибки дополнительно уменьшаются, однако общая картина сохраняется: классические модели показывают более стабильные результаты.

2) Ряд Temperature

Для ряда Temperature лучшие результаты как в recursive forecasting, так и в walk-forward forecasting показала модель ARIMA.

В режиме WF модель показала:

- RMSE = 3.175;
- MAE = 2.417;
- sMAPE = 43.387%.

При этом результаты остальных моделей также оказались достаточно близкими:

- LSTM-WF: RMSE = 3.220;
- Holt-Winters-WF: RMSE = 3.300;
- Naive-WF: RMSE = 3.380.

Разница между моделями оказалась сравнительно небольшой, что говорит о достаточно устойчивой структуре температурного ряда.

На первых 10% тестового интервала качество прогнозирования дополнительно улучшается:

- RMSE = 2.594;
- MAE = 2.011;
- sMAPE = 34.171%.

3) Ряд Bike

Для ряда Bike среди основных моделей наиболее устойчивый результат в режиме WF показала ARIMA-WF:

- RMSE = 1404.880;
- MAE = 950.830;

- sMAPE = 25.830%.

Ближкие результаты показали Holt-Winters-WF и N-BEATS-WF:

- Holt-Winters-WF: RMSE = 1515.530;
- N-BEATS-WF: RMSE = 1537.140.

При этом LSTM-WF показала более высокую ошибку: RMSE = 1638.200.

На первых 10% тестового интервала ситуация заметно меняется.

Лучший результат показывает LSTM-Recursive:

- RMSE = 755.934;
- MAE = 525.381;
- sMAPE = 7.673%.

Таким образом, для ряда Bike качество прогноза сильно зависит от горизонта прогнозирования: на коротком интервале нейросетевые модели показывают более сильные результаты, чем на полном тестовом интервале.

4) Ряд ILI

Для ряда ILI лучший результат в режиме walk-forward forecasting показала модель N-BEATS-WF:

- RMSE = 0.390;
- MAE = 0.255;
- sMAPE = 7.297%.

Ближкие результаты показала ARIMA-WF:

- RMSE = 0.430;
- MAE = 0.240;
- sMAPE = 6.080%.

Различия между лучшими моделями оказались сравнительно небольшими. При этом на данном ряде нейросетевые модели выглядят более конкурентоспособными, чем на остальных датасетах исследования.

В режиме recursive forecasting лучшей моделью стала Holt-Winters-Recursive:

- RMSE = 1.240;

- $MAE = 0.870$;
- $sMAPE = 26.390\%$.

На первых 10% тестового интервала качество дополнительно улучшается:

- $RMSE = 0.485$;
- $MAE = 0.321$;
- $sMAPE = 6.079\%$.

В отличие от ряда *Vike*, качество прогнозирования для *ILI* ухудшается менее резко при увеличении горизонта прогноза.

3.2 Многокритериальное сравнение моделей

Помимо анализа значений метрик качества прогнозирования в рамках работы дополнительно рассматривались вычислительные и практические характеристики моделей. Для более обобщённого сравнения моделей была выполнена многокритериальная оценка по следующим критериям:

- точность прогнозирования;
- время обучения;
- время построения прогноза;
- устойчивость результатов между различными временными рядами;
- требования к объёму данных;
- интерпретируемость;
- сложность настройки.

Для количественных критериев использовалась нормализация значений внутри каждого датасета с последующим переводом результатов в шкалу от 0 до 5, где 0 соответствует наихудшему результату, а 5 соответствует наилучшему результату.

Для критериев, не имеющих прямой количественной оценки, использовались экспертные оценки.

В качестве основы для оценки точности использовались значения $RMSE$ в режиме *walk-forward forecasting*. Устойчивость моделей оценивалась на

основе разброса рангов между различными временными рядами. Итоговые результаты многокритериального сравнения представлены в таблице 6.

Таблица 6 — Многокритериальное сравнение моделей

Критерий	Naïve	ARIMA	Holt-Winters	LSTM	N-BEATS
Точность	3.17	4.40	3.08	1.04	2.40
Обучение	5.00	4.41	4.92	0.00	1.79
Прогноз	5.00	4.00	4.14	0.03	0.04
Устойчивость	0.00	3.72	5.00	0.94	0.00
Данные	5.00	4.00	4.00	2.50	3.00
Интерпретируемость	5.00	4.50	4.50	1.50	2.00
Настройка	5.00	3.50	4.00	2.00	2.00
Итоговая сумма	28.17	28.53	29.64	8.01	11.23
Средняя оценка	4.02	4.08	4.23	1.14	1.60

Результаты многокритериального анализа показывают, что наиболее сбалансированные результаты среди полноценных моделей продемонстрировали ARIMA и Holt-Winters.

Модель Holt-Winters получила наибольшую среднюю оценку благодаря высокой устойчивости результатов, низким вычислительным затратам и сравнительно простой настройке.

ARIMA показала наиболее высокую оценку по точности прогнозирования и также получила высокие оценки по вычислительным характеристикам.

Модель Naïve формально получила высокую итоговую оценку, однако данный результат следует рассматривать отдельно от остальных моделей. Baseline-модель использовалась в работе в первую очередь как опорный уровень качества для сравнения с более сложными подходами. Высокие оценки Naïve в основном связаны с минимальными вычислительными затратами и отсутствием необходимости настройки.

Нейросетевые модели LSTM и N-BEATS получили более низкие итоговые оценки. Основными причинами стали: высокое время обучения, высокое время построения прогноза, более сложная настройка, менее устойчивые результаты между датасетами.

При этом результаты предыдущих разделов показывают, что нейросетевые модели всё же могут показывать хорошие результаты на отдельных рядах и коротких горизонтах прогнозирования.

Поскольку значимость критериев может зависеть от конкретной задачи, дополнительно был рассмотрен вариант с использованием весов. В данном случае основной акцент сделан на точности прогнозирования и устойчивости результатов:

- точность, устойчивость — вес 1;
- время обучения, время прогноза — вес 0.1;
- требования к данным, интерпретируемость, сложность настройки — вес 0.5.

Результаты представлены в таблице 7.

Таблица 7 — Многокритериальное сравнение моделей с учётом весов

Критерий	Naive	ARIMA	Holt-Winters	LSTM	N-BEATS
Точность × 1	3.17	4.40	3.08	1.04	2.40
Обучение × 0.1	0.50	0.44	0.49	0.00	0.18
Прогноз × 0.1	0.50	0.40	0.41	0.00	0.00
Устойчивость × 1	0.00	3.72	5.00	0.94	0.00
Данные × 0.5	2.50	2.00	2.00	1.25	1.50
Интерпретируемость × 0.5	2.50	2.25	2.25	0.75	1.00
Настройка × 0.5	2.50	1.75	2.00	1.00	1.00
Итоговая сумма	11.67	14.96	15.23	4.98	6.08
Средняя оценка	3.53	4.53	4.61	1.51	1.84

При использовании весов распределение моделей становится более показательным. Поскольку основной вес получили точность и устойчивость, baseline-модель Naïve уже не выглядит настолько сильной: несмотря на простоту и минимальные вычислительные затраты, она имеет низкую устойчивость между датасетами.

Наиболее высокие итоговые оценки снова получили Holt-Winters и ARIMA. Holt-Winters немного опережает ARIMA за счёт более высокой устойчивости, а ARIMA показывает лучший результат по точности. Это подтверждает, что классические модели в рамках данного эксперимента оказались наиболее сбалансированными.

Нейросетевые модели LSTM и N-BEATS получили более низкие оценки. Даже при снижении веса вычислительных затрат они уступают классическим моделям из-за меньшей устойчивости и более низких нормализованных оценок точности на полном тестовом интервале.

3.3 Итоговые выводы по результатам эксперимента

Результаты проведённого эксперимента показали, что классические и нейросетевые модели по-разному ведут себя на различных временных рядах.

Классические модели ARIMA и Holt-Winters в большинстве случаев демонстрировали более устойчивые результаты на полном тестовом интервале. Особенно заметно это проявилось на рядах Unemploy и Temperature, где данные модели показывали сравнительно низкие ошибки как в режиме recursive forecasting, так и в режиме walk-forward forecasting. Кроме того, классические подходы характеризовались меньшими вычислительными затратами, более высокой интерпретируемостью и менее сложной настройкой.

Нейросетевые модели LSTM и N-BEATS в ряде случаев показывали конкурентоспособные результаты, однако их качество сильнее зависело от конкретного временного ряда и горизонта прогнозирования. Наиболее сильные результаты нейросетевые модели продемонстрировали на рядах Bike и ILI, особенно на коротком тестовом интервале. Например, для ряда Bike модель LSTM-Recursive на первых 10% тестового интервала показала RMSE=

755.934, что значительно ниже результатов на полном тестовом интервале. Для ряда ILI модель N-BEATS-WF показала лучший результат среди всех моделей в режиме walk-forward forecasting.

При этом на длинном горизонте прогнозирования качество нейросетевых моделей часто ухудшалось сильнее, чем у классических подходов. Это особенно заметно в режиме recursive forecasting, где ошибки моделей LSTM и N-BEATS на полном тестовом интервале оказывались значительно выше, чем на коротком участке тестовой выборки.

Многокритериальный анализ также показал преимущество классических моделей с точки зрения общего баланса характеристик. Наиболее высокие итоговые оценки получили Holt-Winters и ARIMA. Нейросетевые модели получили более низкие оценки из-за больших вычислительных затрат, менее устойчивых результатов между различными рядами и более сложной настройки.

Также результаты эксперимента показали, что использование более сложной архитектуры модели не гарантирует автоматического улучшения качества прогнозирования. На некоторых рядах различия между моделями оказывались сравнительно небольшими, а в отдельных случаях baseline-подход демонстрировал результаты, сопоставимые с более сложными моделями.

Таким образом, проведённый эксперимент показывает, что выбор модели прогнозирования должен зависеть от особенностей временного ряда и требований задачи. Классические модели в рамках исследования продемонстрировали более устойчивое и сбалансированное качество, тогда как нейросетевые подходы оказались более чувствительными к данным и условиям прогнозирования, но при этом в отдельных случаях позволяли получать более точные прогнозы.

4 Разработка программной системы

В рамках работы была разработана простая программная система для автоматизации вычислительного эксперимента. По сути, внутри системы находится скрипт эксперимента, который был вынесен из исследовательского ноутбука и оформлен в виде отдельного консольного приложения. Это было сделано для того, чтобы запуск эксперимента был более удобным, воспроизводимым и не зависел от ручного выполнения ячеек в ноутбуке.

Система реализована на языке Python. Пользователь запускает основной файл `run_experiment.py`, после чего в консоли указывает параметры эксперимента: путь к CSV-файлу, колонку с датой, колонку с целевой переменной, тип временного ряда и режим прогнозирования. После этого система автоматически выполняет основные этапы эксперимента: загружает данные, приводит их к единому формату, делит ряд на обучающую, валидационную и тестовую выборки, запускает модели, считает метрики и сохраняет результаты.

Общая схема работы системы представлена на рисунке 5.




Рисунок 5 – Общая схема работы программной системы

Структура проекта представлена на рисунке 6.




Рисунок 6 – Структура проекта

Пример работы системы представлен на рисунках 7-9. На рисунке 7 показан процесс запуска эксперимента через консольный интерфейс: пользователь указывает путь к файлу, выбирает колонку с датой, целевую переменную, тип временного ряда, режим прогнозирования и название эксперимента.

```
=====
MVP системы сравнения моделей прогнозирования временных рядов
=====
Введите путь к CSV-файлу: data/unemploy.csv

Найдены колонки:
1. observation_date
2. UNEMPLOY

Выберите колонку с датой: observation_date

Найдены колонки:
1. observation_date
2. UNEMPLOY

Выберите колонку с целевой переменной: UNEMPLOY

Выберите тип временного ряда:
1. hourly
2. daily
3. weekly
4. monthly
5. yearly

Ваш выбор: monthly

Выберите тип прогнозирования:
1. recursive – следующий шаг использует предыдущий прогноз
2. walk_forward – следующий шаг использует фактическое значение из test
3. both – запустить оба режима
```

Рисунок 7 – Пример задания параметров через консольный интерфейс

После выбора параметров система последовательно выполняет загрузку и подготовку данных, разбиение выборки, запуск моделей и расчёт метрик. В конце работы в консоль выводится итоговая таблица с результатами, пример которой представлен на рисунке 8.

```
{ 'forecast_mode': 'recursive' } 3183.471697 1494.234043 16.684425 0.000000 0.000000
ARIMA-Recursive ARIMA recursive
{'order': (2, 1, 1), 'forecast_mode': 'recursive'} 3278.145114 1537.861718 17.299493 0.475993 0.207707
LSTM-Recursive LSTM recursive {'window_size': 12, 'hidden_size': 32, 'e
': 20, 'batch_size': 32, 'forecast_mode': 'recursive'} 3326.301280 2423.188709 28.294053 3.743017 6.974193
N-BEATS-Recursive N-BEATS recursive {'window_size': 12, 'hidden_size': 64, 'num_blocks': 2, 'num_layers': 2, 'e
': 20, 'batch_size': 32, 'forecast_mode': 'recursive'} 7327.853866 6451.590982 153.181636 2.922596 6.781714

Сравнение full test vs первые 10% test
model forecast_mode RMSE_full MAE_full SMAPE_full n_points RMSE_short_10 MAE_short_10 SMAPE_short_10
ARIMA-WF walk_forward 1739.764148 468.669923 4.426644 9 186.813802 164.618619 2.624381
Naive-WF walk_forward 1748.477228 478.468085 4.493859 9 187.028221 164.666667 2.625208
Holt-Winters-WF walk_forward 1749.234708 478.870016 4.495763 9 187.028220 164.666666 2.625208
N-BEATS-WF walk_forward 2077.750081 995.628058 10.536573 9 480.868057 445.104668 6.884493
LSTM-WF walk_forward 2476.651032 1013.784816 9.966190 9 383.224584 334.564712 5.220561
Holt-Winters-Recursive recursive 3183.471697 1494.234043 16.684425 9 249.099429 211.376532 3.349562
Naive-Recursive recursive 3183.471697 1494.234043 16.684425 9 250.512807 211.777778 3.355832
ARIMA-Recursive recursive 3278.145114 1537.861718 17.299493 9 179.810536 167.559943 2.668394
LSTM-Recursive recursive 3326.301280 2423.188709 28.294053 9 631.476362 617.930180 9.440138
N-BEATS-Recursive recursive 7327.853866 6451.590982 153.181636 9 1323.389406 1156.089839 20.946657

Артефакты сохранены в папку:
results/unemploy
PS C:\Users\User\Downloads\диплом\time series mvp> |
```

Рисунок 8 – Пример вывода после выполнения эксперимента

Кроме вывода результатов в консоль, система сохраняет артефакты эксперимента в отдельную папку внутри директории results. Пример структуры сохранённых результатов представлен на рисунке 9. В результате запуска сохраняются таблицы с метриками, прогнозы моделей, графики, конфигурация эксперимента и текстовый лог.




Рисунок 9 – Пример сохранения артефактов эксперимента

Файл `run_experiment.py` является точкой входа в систему. Он отвечает за взаимодействие с пользователем: запрашивает путь к файлу, показывает найденные колонки, предлагает выбрать колонку с датой и целевой переменной, а также выбрать тип временного ряда и режим прогнозирования.

Файл `experiment.py` содержит основную логику эксперимента. В нём последовательно выполняются загрузка данных, разбиение выборки, запуск моделей, расчёт метрик и сохранение результатов. Таким образом, система представляет собой не отдельный сложный программный продукт, а удобную оболочку над экспериментальным скриптом.

Модуль `data.py` отвечает за подготовку данных. Он загружает CSV-файл, автоматически пытается определить разделитель, проверяет наличие выбранных колонок, приводит дату к формату `datetime`, а целевую переменную

к числовому типу. Затем данные сортируются по дате и очищаются от некорректных значений.

Модуль `config.py` хранит настройки, которые зависят от типа временного ряда. Например, для месячного ряда задаётся сезонный период 12 и набор размеров окон для нейросетевых моделей. Это позволяет не привязывать систему к конкретному датасету, а настраивать её по частоте ряда.

Модуль `models.py` содержит реализацию используемых моделей: Naïve baseline, ARIMA, Holt-Winters, LSTM и N-BEATS. Для прогнозирования предусмотрены два режима: `recursive` и `walk-forward`. В режиме `recursive` модель строит длинный прогноз, используя собственные предыдущие прогнозы. В режиме `walk-forward` модель на каждом шаге получает фактическое значение из тестовой выборки и строит следующий одношаговый прогноз.

Модуль `metrics.py` считает метрики RMSE, MAE и sMAPE. Метрики рассчитываются для полного тестового горизонта и отдельно для первых 10% тестовой выборки. Это позволяет дополнительно оценить качество прогноза на коротком участке, где ошибка ещё не успевает сильно накопиться.

После запуска для каждого эксперимента создаётся отдельная папка в директории `results`. В неё сохраняются прогнозы моделей, таблицы с метриками, графики, конфигурация запуска и текстовый лог. Такой формат удобен, потому что результаты разных запусков не смешиваются между собой.

Важно отметить, что скорость работы программной системы не является ключевым фактором в рамках данной работы. Система не рассматривается как промышленное решение для быстрого прогнозирования в реальном времени. Её основная задача состоит в автоматизации вычислительного эксперимента, сохранении результатов и обеспечении возможности сравнить модели между собой в одинаковых условиях.

Поэтому при разработке системы основной акцент был сделан не на оптимизацию времени выполнения, а на удобство запуска эксперимента, воспроизводимость, сохранение артефактов и возможность анализа

результатов. Система позволяет не только получить значения метрик качества, но и сравнить модели с точки зрения практического использования: качества прогноза, устойчивости, сложности настройки и удобства интерпретации. Это помогает выбрать не просто самую быструю модель, а наиболее подходящую и удобную модель для рассматриваемой задачи прогнозирования.

Основная цель разработанной системы заключается не в создании полноценного промышленного приложения, а в автоматизации и воспроизводимости эксперимента, проведённого в рамках выпускной квалификационной работы.

ЗАКЛЮЧЕНИЕ

В рамках выпускной квалификационной работы был проведён сравнительный анализ классических и нейросетевых моделей прогнозирования временных рядов на данных различной природы. В исследовании были рассмотрены классические модели ARIMA и Holt-Winters, а также нейросетевые модели LSTM и N-BEATS. Эксперимент проводился на нескольких временных рядах, отличающихся предметной областью, частотой наблюдений, уровнем сезонности и структурой зависимостей.

В ходе работы были изучены теоретические основы прогнозирования временных рядов, рассмотрены особенности временных данных, основные подходы к прогнозированию, а также метрики оценки качества прогнозов. Отдельное внимание было уделено сравнению классических и нейросетевых подходов с точки зрения их сильных и слабых сторон.

В практической части работы были выполнены сбор, подготовка и предобработка временных рядов, реализован вычислительный эксперимент и проведено сравнение моделей в одинаковых условиях. Для всех моделей использовались единые правила разделения данных, единые метрики качества и единая схема оценки результатов. Также были рассмотрены два режима прогнозирования: recursive forecasting и walk-forward forecasting.

Результаты эксперимента показали, что классические модели ARIMA и Holt-Winters в рамках данного исследования продемонстрировали более устойчивые и сбалансированные результаты на полном тестовом интервале. Они обеспечивали сравнительно низкие ошибки прогнозирования, меньшие вычислительные затраты, более высокую интерпретируемость и менее сложную настройку. Нейросетевые модели LSTM и N-BEATS в отдельных случаях показывали конкурентоспособные результаты, особенно на коротких горизонтах прогнозирования, однако в целом оказались более чувствительными к особенностям данных и настройке гиперпараметров.

Помимо вычислительного эксперимента в рамках работы была разработана программная система, автоматизирующая процесс проведения

эксперимента. Система позволяет выполнять загрузку и подготовку данных, запуск моделей, расчёт метрик и сохранение результатов в едином воспроизводимом формате.

Таким образом, поставленная цель работы была достигнута и все поставленные задачи были выполнены.

Полученные результаты показывают, что более сложные нейросетевые архитектуры не всегда обеспечивают преимущество по сравнению с классическими подходами. Выбор модели должен зависеть от особенностей временного ряда, требований к интерпретируемости, доступных вычислительных ресурсов и характера прогнозируемой задачи.

Работа имеет и возможные направления дальнейшего развития. В будущем исследование может быть расширено за счёт использования большего количества временных рядов и более разнообразных предметных областей. Также перспективным направлением является более глубокая настройка гиперпараметров моделей, использование более сложных нейросетевых архитектур, добавление экзогенных признаков и переход к многомерным временным рядам. Дополнительно возможно развитие разработанной программной системы: реализация графического интерфейса, поддержка новых моделей прогнозирования, автоматизация подбора параметров и расширение средств визуализации результатов эксперимента.

В целом проведённая работа подтверждает актуальность сравнительного анализа моделей прогнозирования временных рядов и показывает, что классические методы по-прежнему остаются конкурентоспособными и практически значимыми даже на фоне современных нейросетевых подходов.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Афанасьев В. Н., Юзбашев М. М. Анализ временных рядов и прогнозирование : учебник. — Москва : Финансы и статистика, 2001. — 228 с.
2. Haben S., Voss M., Holderbaum W. Time Series Forecasting: Core Concepts and Definitions [Электронный ресурс] // Explainable AI and Other Applications of Fuzzy Techniques. — Cham : Springer, 2023. — URL: https://link.springer.com/chapter/10.1007/978-3-031-27852-5_5 (дата обращения: 14.05.2026).
3. Артамонов Н. В., Ивин Е. А., Курбацкий А. Н. Введение в анализ временных рядов. — Санкт-Петербург : Университет ИТМО, 2021. — 92с.
4. Hyndman R. J., Athanasopoulos G. Forecasting: Principles and Practice [Электронный ресурс]. — 3rd ed. — Melbourne : OTexts, 2021. — URL: <https://otexts.com/fpp3/planning.html> (дата обращения: 14.05.2026).
5. Artificial intelligence and classical statistical models for time series forecasting: a comprehensive review [Электронный ресурс] // Journal of Big Data. — 2025. — URL: <https://link.springer.com/article/10.1186/s40537-025-01318-z> (дата обращения: 14.05.2026).
6. Тихонов Э. Е. Методы прогнозирования в условиях рынка. — Москва : Невский диалект, 2006. — 221 с.
7. Box G. E. P., Jenkins G. M., Reinsel G. C., Ljung G. M. Time Series Analysis: Forecasting and Control. — 5th ed. — Hoboken : Wiley, 2015. — 712 p.
8. Hamilton J. D. Time Series Analysis. — Princeton : Princeton University Press, 1994. — 799 p.
9. Dickey D. A., Fuller W. A. Distribution of the Estimators for Autoregressive Time Series With a Unit Root // Journal of the American Statistical Association. — 1979. — Vol. 74, No. 366. — P. 427–431.

10. Holt C. C. Forecasting Seasonals and Trends by Exponentially Weighted Moving Averages // International Journal of Forecasting. — 2004. — Vol. 20, No. 1. — P. 5–10.
11. Winters P. R. Forecasting Sales by Exponentially Weighted Moving Averages // Management Science. — 1960. — Vol. 6, No. 3. — P. 324–342.
12. Goodfellow I., Bengio Y., Courville A. Deep Learning. — Cambridge : MIT Press, 2016. — 800 p.
13. Makridakis S., Spiliotis E., Assimakopoulos V. Statistical and Machine Learning Forecasting Methods: Concerns and Ways Forward [Электронный ресурс] // PLoS ONE. — 2018. — Vol. 13, No. 3. — URL: <https://doi.org/10.1371/journal.pone.0194889> (дата обращения: 14.05.2026).
14. Hochreiter S., Schmidhuber J. Long Short-Term Memory // Neural Computation. — 1997. — Vol. 9, No. 8. — P. 1735–1780.
15. Oreshkin B. N., Carпов D., Chapados N., Bengio Y. N-BEATS: Neural Basis Expansion Analysis for Interpretable Time Series Forecasting [Электронный ресурс] // International Conference on Learning Representations (ICLR). — 2020. — URL: <https://openreview.net/forum?id=r1ecqn4YwB> (дата обращения: 14.05.2026).
16. An experimental comparison of classic statistical techniques on univariate time series forecasting [Электронный ресурс] // Procedia Computer Science. — 2024. — URL: <https://www.sciencedirect.com/science/article/pii/S1877050924009335> (дата обращения: 14.05.2026).
17. Makridakis S., Spiliotis E., Assimakopoulos V. The M4 Competition: Results, findings, conclusion and way forward [Электронный ресурс] // International Journal of Forecasting. — 2018. — Vol. 34, No. 4. — P. 802–808. — URL: <https://doi.org/10.1016/j.ijforecast.2018.06.001> (дата обращения: 14.05.2026).

- 18.Meisenbacher S., Schmoll M., Jannach D. Review of Automated Time Series Forecasting Pipelines [Электронный ресурс] // arXiv preprint arXiv:2202.01712. — 2022. — URL: <https://arxiv.org/abs/2202.01712> (дата обращения: 14.05.2026).
- 19.Federal Reserve Economic Data (FRED). Unemployment Level [UNEMPLOY] [Электронный ресурс]. — URL: <https://fred.stlouisfed.org/series/UNEMPLOY> (дата обращения: 14.05.2026).
- 20.Czech Hydrometeorological Institute. Prague Weather Data Archive [Электронный ресурс]. — URL: <https://dev.meteostat.net/data/timeseries/hourly> (дата обращения: 14.05.2026).
- 21.Daily Bike Sharing Demand Dataset [Электронный ресурс] // UCI Machine Learning Repository. — URL: <https://archive.ics.uci.edu/dataset/275/bike+sharing+dataset> (дата обращения: 14.05.2026).
- 22.Centers for Disease Control and Prevention (CDC). Weekly U.S. Influenza Surveillance Report [Электронный ресурс]. — URL: <https://www.cdc.gov/fluview/overview/fluview-interactive.html> (дата обращения: 14.05.2026).
- 23.Seabold S., Perktold J. Statsmodels: Econometric and Statistical Modeling with Python // Proceedings of the 9th Python in Science Conference. — 2010. — P. 92–96.
- 24.Pedregosa F. et al. Scikit-learn: Machine Learning in Python // Journal of Machine Learning Research. — 2011. — Vol. 12. — P. 2825–2830.

ПРИЛОЖЕНИЕ А

Графики выбранных временных рядов




Рисунок А.1 – Ряд Unemploy




Рисунок А.2 – Ряд Temperature




Рисунок А.3 – Ряд Bike




Рисунок А.4 – Ряд ILI

ПРИЛОЖЕНИЕ В

Таблицы с полными результатами вычислительного эксперимента

Таблица В.1 — Метрики качества

Ряд	Режим	Модель	RMSE	MAE	sMAPE
Unemploy	Recursive	Naive	3285.934	1545.372	17.390
Unemploy	Recursive	ARIMA	3426.942	1605.721	18.266
Unemploy	Recursive	Holt-Winters	4996.991	3939.242	68.250
Unemploy	Recursive	LSTM	4780.164	3951.177	41.808
Unemploy	Recursive	N-BEATS	3834.804	3444.101	37.906
Unemploy	WF	Naive	1748.220	475.670	4.450
Unemploy	WF	ARIMA	1794.159	500.543	4.510
Unemploy	WF	Holt-Winters	1748.220	475.670	4.450
Unemploy	WF	LSTM	2740.944	1023.838	8.926
Unemploy	WF	N-BEATS	2155.675	856.395	8.779
Temperature	Recursive	Naive	9.145	7.769	73.309
Temperature	Recursive	ARIMA	8.916	7.554	73.171
Temperature	Recursive	Holt-Winters	9.073	7.704	73.210
Temperature	Recursive	LSTM	19.651	17.651	98.162
Temperature	Recursive	N-BEATS	28.704	27.148	116.160
Temperature	WF	Naive	3.381	2.493	42.042
Temperature	WF	ARIMA	3.175	2.417	43.387
Temperature	WF	Holt-Winters	3.298	2.464	44.457
Temperature	WF	LSTM	3.217	2.464	44.854
Temperature	WF	N-BEATS	3.426	2.652	45.361
Bike	Recursive	Naive	3308.061	2772.324	51.724
Bike	Recursive	ARIMA	3308.061	2772.324	51.724
Bike	Recursive	Holt-Winters	2776.627	2236.358	45.349
Bike	Recursive	LSTM	3657.109	3062.272	54.650
Bike	Recursive	N-BEATS	1670.774	1192.801	30.618
Bike	WF	Naive	1332.242	930.838	28.115
Bike	WF	ARIMA	1404.880	950.828	25.834
Bike	WF	Holt-Winters	1515.533	1043.375	27.429
Bike	WF	LSTM	1638.197	1061.435	27.630
Bike	WF	N-BEATS	1537.142	1037.137	26.974
ILI	Recursive	Naive	1.981	1.755	54.073
ILI	Recursive	ARIMA	2.124	1.879	56.468
ILI	Recursive	Holt-Winters	1.240	0.870	26.390
ILI	Recursive	LSTM	1.708	1.343	43.818
ILI	Recursive	N-BEATS	4.050	3.706	82.625
ILI	WF	Naive	0.534	0.325	8.561

ILI	WF	ARIMA	0.434	0.238	6.084
ILI	WF	Holt-Winters	0.491	0.257	6.311
ILI	WF	LSTM	0.616	0.357	9.684
ILI	WF	N-BEATS	0.390	0.255	7.297

Таблица В.2 — Время обучения и построения прогноза моделей

Ряд	Режим	Модель	Обучение, с	Прогноз, с
Unemploy	Recursive	Naive	0.000	0.000
Unemploy	Recursive	ARIMA	0.691	0.005
Unemploy	Recursive	Holt-Winters	1.184	0.012
Unemploy	Recursive	LSTM	5.737	7.363
Unemploy	Recursive	N-BEATS	2.720	7.276
Unemploy	WF	Naive	0.000	0.000
Unemploy	WF	ARIMA	0.575	0.942
Unemploy	WF	Holt-Winters	0.005	0.272
Unemploy	WF	LSTM	5.743	7.354
Unemploy	WF	N-BEATS	3.556	7.153
Temperature	Recursive	Naive	0.000	0.000
Temperature	Recursive	ARIMA	0.799	0.013
Temperature	Recursive	Holt-Winters	0.008	0.004
Temperature	Recursive	LSTM	8.327	33.869
Temperature	Recursive	N-BEATS	5.914	33.327
Temperature	WF	Naive	0.000	0.000
Temperature	WF	ARIMA	3.067	14.452
Temperature	WF	Holt-Winters	0.009	3.995
Temperature	WF	LSTM	12.438	33.764
Temperature	WF	N-BEATS	6.574	34.165
Bike	Recursive	Naive	0.000	0.000
Bike	Recursive	ARIMA	0.009	0.003

Bike	Recursive	Holt-Winters	0.150	0.010
Bike	Recursive	LSTM	3.224	5.851
Bike	Recursive	N-BEATS	3.257	5.760
Bike	WF	Naive	0.000	0.000
Bike	WF	ARIMA	0.350	0.549
Bike	WF	Holt-Winters	0.211	1.517
Bike	WF	LSTM	3.945	5.774
Bike	WF	N-BEATS	3.345	5.744
ILI	Recursive	Naive	0.000	0.000
ILI	Recursive	ARIMA	0.251	0.004
ILI	Recursive	Holt-Winters	1.453	0.015
ILI	Recursive	LSTM	3.896	9.748
ILI	Recursive	N-BEATS	3.815	9.682
ILI	WF	Naive	0.000	0.000
ILI	WF	ARIMA	0.264	1.516
ILI	WF	Holt-Winters	0.045	2.653
ILI	WF	LSTM	6.689	9.540
ILI	WF	N-BEATS	3.847	9.636